

AstroVision

Global Solution – DevOps

Global Solution – 2026 – 4ESPX

Grupo

- Vinícius Almeida Bernardino de Souza | RM 97888
- João Pedro Borsato Cruz | RM 550294
- Maria Fernanda Vieira de Camargo | RM 97956
- Pedro Lucas de Andrade Nunes | RM 550366
- Fernanda Kaory Saito | RM 551104

Problema

Eventos climáticos extremos figuram entre os fenômenos mais devastadores da atualidade, impactando diretamente vidas humanas, ecossistemas e economias nacionais. A intensificação dessas ocorrências, amplificada pelas mudanças climáticas globais, eleva exponencialmente a demanda por sistemas de monitoramento eficazes, rápidos e escaláveis.

O monitoramento tradicional enfrenta três limitações críticas:

1. Velocidade insuficiente: A análise manual de imagens satelitais demanda horas ou dias, enquanto desastres se alastram em minutos. A janela de resposta efetiva é frequentemente perdida.
2. Escala operacional limitada: O volume crescente de dados gerados por satélites de observação terrestre supera a capacidade de análise de especialistas humanos, criando gargalos críticos em situações de emergência.
3. Ausência de interpretabilidade: Modelos de IA existentes operam como caixas-pretas, impossibilitando a validação científica das previsões e limitando sua adoção institucional por órgãos de defesa civil e pesquisa.

Dataset

O dataset foi composto por imagens reais de eventos climáticos divididas em duas categorias:

- Wildfire (Incêndios): 50 imagens
- Flood (Enchentes): 51 imagens

Tratamento e Preparação dos Dados

Etapas do Pré-processamento

Leitura

As imagens foram carregadas utilizando a biblioteca OpenCV.

```
img = cv2.imread(caminho)
```

Conversão de Cor

O OpenCV utiliza o padrão BGR por padrão, enquanto a maioria dos modelos de Deep Learning trabalha com RGB

Por isso foi realizada a conversão:

```
img = cv2.cvtColor(  
    img,  
    cv2.COLOR_BGR2RGB  
)
```

Redimensionamento

Como as imagens possuíam tamanhos diferentes, todas foram redimensionadas para 224x224 pixels.

```
img = cv2.resize(  
    img,  
    (IMG_SIZE, IMG_SIZE)  
)
```

Normalização

Os valores foram convertidos do intervalo 0-255 para 0-1.

```
img = img / 255.0
```

Divisão dos Dados

O conjunto de dados foi dividido em:

- Treinamento: 70%
- Validação: 15%
- Teste: 15%

```
x_train, x_temp, y_train, y_temp = train_test_split(
    x,
    y,
    test_size=0.30,
    random_state=42,
    stratify=y
)

x_val, x_test, y_val, y_test = train_test_split(
    x_temp,
    y_temp,
    test_size=0.50,
    random_state=42,
    stratify=y_temp
)
```

Técnicas para Treinamento do Modelo

Foi desenvolvida uma Rede Neural Convolucional (CNN) do zero utilizando TensorFlow/Keras.

Camadas da Rede

Entrada

(224 x 224 x 3) Imagens RGB

Data Augmentation

Para aumentar artificialmente a diversidade do dataset foram aplicadas transformações aleatórias:

- Flip Horizontal
- Rotação
- Zoom

Extração de Características

Foram utilizadas 3 camadas convolucionais:

- Conv2D (32 filtros)
- Conv2D (64 filtros)
- Conv2D (128 filtros)

Essas camadas identificam padrões visuais como bordas, texturas, formas, regiões queimadas, áreas inundadas.

Redução de Dimensionalidade

Após cada convolução foi utilizada uma camada MaxPooling2D para reduzir a quantidade de parâmetros em melhorar a eficiência computacional.

Classificação

As características extraídas foram enviadas para

- Flatten
- Dense(128)
- Dropout(0.5)
- Dense(1)

A camada final utiliza Sigmoid para produzir uma classificação binária.

Otimizador

Foi utilizado o algoritmo Adam por apresentar rápida convergência e bom desempenho em problemas de classificação.

Função de Perda

Para evitar overfitting foi implementado:

```
early_stop = EarlyStopping(  
    monitor="val_loss",  
    patience=5,  
    restore_best_weights=True  
)
```

Fazendo com que o treinamento seja interrompido automaticamente quando não há melhoria na validação.

Avaliação do Modelo Utilizando Métricas de Desempenho

Accuracy

A principal métrica utilizada foi a acurácia, com um resultado de 81,25%

Precision

Mede quantas previsões positivas estavam corretas:

- 0.73 para enchentes
- 1.00 para incêndios

Recall

Quantos exemplos reais foram encontrados pelo modelo

- 1.00 para enchentes
- 0.62 para incêndios

F1-Score

Combina Precision e Recall em uma única métrica

- 0.84 para enchentes
- 0.77 para incêndios


Avaliação Visual do Modelo

Matriz de Confusão

Permite visualizar:

- Acertos
- Falsos Positivos
- Falsos Negativos

Arquivo: confusion_matrix.png




Demonstra que a maioria das imagens foram corretamente classificadas.

Curva de Accuracy

Mostra a evolução da acurácia ao longo das épocas de treinamento.

Arquivo: accuracy.png




A proximidade entre as curvas de treino e validação indica boa capacidade de generalização.

Curva de Loss

Apresenta a redução do erro durante o treinamento.

Arquivo: loss.png



Observou-se uma diminuição consistente da função de perda ao longo das épocas, indicando aprendizado efetivo da rede neural